

Laborator Suplimentar

Mersul la întâmplare simplu

Obiectivul acestui laborator este de a rezolva câteva probleme ce țin de mersul la întâmplare simplu cu ajutorul limbajului R.

1 Ruina jucătorului



Un bărbat vrea să își cumpere un obiect (de exemplu o mașină sau o casă) care costă N unități monetare. Să presupunem că el are economisit un capital de $0 < k < N$ unități monetare și încearcă să câștige restul jucând un joc de noroc cu managerul unei bănci. Jocul este următorul: bărbatul aruncă o monedă echilibrată în mod repetat și dacă moneda pică cap (H) atunci managerul îi dă o unitate monetară, în caz contrar bărbatul plătește o unitate monetară bancii. Jocul continuă până când unul din două evenimente se realizează: sau câștigă suma necesară și își cumpără obiectul dorit sau pierde banii și ajunge la faliment. Ne întrebăm care este probabilitatea să ajungă la faliment?

Fie A evenimentul ca bărbatul să ajungă la ruină și B evenimentul ca la prima aruncare moneda a picat cap. Atunci din formula probabilității totale avem

$$\mathbb{P}_k(A) = \mathbb{P}_k(A|B)\mathbb{P}(B) + \mathbb{P}_k(A|B^c)\mathbb{P}(B^c)$$

unde \mathbb{P}_k este probabilitatea calculată în funcție de valoarea k a capitalului inițial al jucătorului. Să observăm că $\mathbb{P}_k(A|B)$ devine $\mathbb{P}_{k+1}(A)$ deoarece dacă la prima aruncare avem cap atunci capitalul inițial a crescut la $k + 1$. În mod similar, dacă la prima aruncare am obținut coadă atunci $\mathbb{P}_k(A|B^c) = \mathbb{P}_{k-1}(A)$. Notând cu $p_k = \mathbb{P}_k(A|B)$ obținem următoarea ecuație

$$p_k = \frac{1}{2}p_{k+1} + \frac{1}{2}p_{k-1},$$

cu valorile inițiale $p_0 = 1$ (dacă jucătorul a pornit cu un capital inițial nul atunci el este în faliment) și respectiv $p_N = 0$ (dacă jucătorul are din start suma necesară pentru a achiziționa obiectul dorit atunci nu mai are loc jocul).

O simulare a jocului pentru $N = 50$ și $k = 5$ este prezentată de următoarea funcție:


```
ruina = function(N, k){  
  flag = TRUE  
  
  joc = 0  
  capital = k  
  y = capital  
  
  while(flag){  
    x = 2*rbinom(1,1,0.5)-1  
  
    capital = capital + x  
    y = c(y, capital)
```

```
joc = joc + 1

if (capital == 0 || capital == N){
  flag = FALSE
}
}

return(y) # daca am 0 este ruina altfel este succes
}
```

Ruina jucatorului



Dacă definim $b_k = p_k - p_{k-1}$ pentru $k \geq 1$ atunci $b_k = b_{k-1}$, $\forall k \geq 2$. Prin urmare $b_k = b_1$ și $p_k = b_1 + p_{k-1} = kb_1 + p_0$. Observând că $b_1 + \dots + b_N = p_N - p_0 = -1$ deducem că $b_1 = -\frac{1}{N}$ iar $p_k = 1 - \frac{k}{N}$.

Dorim să repetăm experimentul de $M = 1000$ de ori (pentru valorile inițiale $N = 50$ și $k = 5$) și ne interesăm de câte ori jucătorul a ajuns la faliment.

```
N = 50
k = 5
M = 1000
# Obs. - rezultatul functiei ruina trebuie modificat
joc = replicate(M, ruina(N, k)) # repeta functia de M ori

proba_ruina = sum(joc == 0)/M
```

Am obținut că probabilitatea empirică de faliment este 0.9 iar cea teoretică este 0.9.

2 Aruncatul cu banul



O monedă are probabilitatea să pice cap p și să pice coadă q astfel ca $p + q = 1$. Moneda este aruncată succesiv și independent până când evenimentul A , am obținut două capete unul după altul sau două cozi una după alta, s-a realizat. Determinați numărul mediu de aruncări necesare realizării evenimentului A .

Vom prezenta două soluții pentru acest exercițiu. În prima soluție vom începe prin a calcula funcția de masă pentru variabila care descrie experimentul și apoi vom calcula media. În cea de-a doua soluție vom calcula media cu ajutorul condiționării.

Fie X variabila aleatoare care reprezintă numărul de aruncări necesare pentru ca evenimentul A să se realizeze (numărul de aruncări necesare obținerii a 2 capete unul după altul sau a 2 cozi una după alta) și $X_i \in \{H, T\}$ variabila aleatoare care descrie rezultatul obținut la cea de-a i -a aruncare. Evenimentul $\{X = n\}$ poate fi exprimat ca reuniunea dintre A_n și B_n , unde A_n reprezintă evenimentul să obținem două capete consecutive pentru prima oară la cea de-a n -a aruncare iar B_n este evenimentul să obținem două cozi consecutive la a n -a aruncare.

Se poate observa cu ușurință că un eveniment elementar din A_n are forma $\omega = \underbrace{\cdots}_{n-2} HH$ și se poate determina în întregime datorită faptului că în primele $n - 2$ aruncări nu putem avea două realizări consecutive. În plus dacă $n = 2k + 1$ atunci

$$\mathbb{P}(A_{2k+1}) = \mathbb{P}(X_1 = T, X_2 = H, \dots, X_{2k-1} = T, X_{2k} = H, X_{2k+1} = H) \stackrel{\text{indep.}}{=} (pq)^k p$$

iar dacă $n = 2k + 2$ atunci

$$\mathbb{P}(A_{2k+2}) = \mathbb{P}(X_1 = H, X_2 = T, \dots, X_{2k} = T, X_{2k+1} = H, X_{2k+2} = H) \stackrel{\text{indep.}}{=} (pq)^k p^2$$

În mod similar se poate calcula probabilitatea evenimentului B_n pentru $n = 2k + 1$

$$\mathbb{P}(B_{2k+1}) = \mathbb{P}(X_1 = H, X_2 = T, \dots, X_{2k-1} = H, X_{2k} = T, X_{2k+1} = T) \stackrel{\text{indep.}}{=} (pq)^k q$$

și respectiv $n = 2k + 2$

$$\mathbb{P}(B_{2k+2}) = \mathbb{P}(X_1 = T, X_2 = H, \dots, X_{2k} = H, X_{2k+1} = T, X_{2k+2} = T) \stackrel{\text{indep.}}{=} (pq)^k q^2$$

Cum $\mathbb{P}(X = n) = \mathbb{P}(A_n) + \mathbb{P}(B_n)$ deducem că

$$\mathbb{P}(X = n) = \begin{cases} (pq)^{\frac{n-1}{2}}, & n \text{ impar} \\ (pq)^{\frac{n-2}{2}}(p^2 + q^2), & n \text{ par} \end{cases}$$

Următoarea funcție simulează evenimentul din enunțul problemei:

```
flip_coins = function(p){  
  
  flip = sample(c("H", "T"), 1, prob = c(p, 1-p))  
  
  nflips = 1  
  flag = TRUE
```

```
while(flag){  
  x = sample(c("H", "T"), 1, prob = c(p, 1-p))  
  
  nflips = nflips + 1  
  
  if (flip == x){  
    flag = FALSE  
  }  
  
  flip = x  
}  
  
return(nflips)  
}  
  
flip_coins(0.2)  
[1] 3
```

Înainte de a calcula media ne propunem să repetăm de $N = 10000$ de ori experimentul (pentru $p = 0.3$) și să comparăm rezultatul empiric cu cel teoretic.

```
N = 10000  
p = 0.3  
  
rez_flips = replicate(N, flip_coins(p))
```

Rezultatele sunt incluse în tabelul de mai jos:

n	Empiric	Teoretic
2	0.5760	0.58000
3	0.2110	0.21000
4	0.1245	0.12180
5	0.0434	0.04410
6	0.0255	0.02558
7	0.0100	0.00926
8	0.0059	0.00537
9	0.0016	0.00194
10	0.0014	0.00113
11	0.0004	0.00041
12	0.0002	0.00024
13	0.0001	0.00009

Pentru a calcula media avem

$$\mathbb{E}[X] = \sum_{n=2}^{\infty} n\mathbb{P}(X = n)$$

iar dacă seriile $\sum_{k=1}^{\infty} (2k+1)\mathbb{P}(X = 2k+1)$ și $\sum_{k=0}^{\infty} (2k+2)\mathbb{P}(X = 2k+2)$ sunt convergente atunci putem scrie

$$\mathbb{E}[X] = \sum_{n=2}^{\infty} n\mathbb{P}(X = n) = \sum_{k=1}^{\infty} (2k+1)\mathbb{P}(X = 2k+1) + \sum_{k=0}^{\infty} (2k+2)\mathbb{P}(X = 2k+2).$$

Se poate arăta cu ușurință că

$$\sum_{k=1}^{\infty} (2k+1) \mathbb{P}(X = 2k+1) = 2 \sum_{k=1}^{\infty} (k+1)(pq)^k - \sum_{k=1}^{\infty} (pq)^k = \frac{pq(3-pq)}{(1-pq)^2}$$

și

$$\sum_{k=0}^{\infty} (2k+2) \mathbb{P}(X = 2k+2) = 2(p^2 + q^2) \sum_{k=0}^{\infty} (k+1)(pq)^k = \frac{2(p^2 + q^2)}{(1-pq)^2}$$

de unde concluzionăm că $\mathbb{E}[X] = \frac{pq(3-pq)}{(1-pq)^2} + \frac{2(p^2+q^2)}{(1-pq)^2} = \frac{2+pq}{1-pq}$.

O a doua soluție pentru determinarea mediei este bazată pe condiționare. Fie H_k și respectiv T_k evenimentele prin care capul respectiv coada a apărut la cea de-a k -a aruncare și $\mathbb{P}(H_k) = p$ iar $\mathbb{P}(T_k) = q$. Din formula probabilității totale, avem că

$$\mathbb{E}[X] = \mathbb{E}[X|H_1]\mathbb{P}(H_1) + \mathbb{E}[X|T_1]\mathbb{P}(T_1) = p\mathbb{E}[X|H_1] + q\mathbb{E}[X|T_1].$$

Mai mult,

$$\mathbb{E}[X|H_1] = p\mathbb{E}[X|H_1 \cap H_2] + q\mathbb{E}[X|H_1 \cap T_2]$$

și cum $\mathbb{E}[X|H_1 \cap H_2] = 2$ (evenimentul A s-a realizat la a doua aruncare) iar $\mathbb{E}[X|H_1 \cap T_2] = 1 + \mathbb{E}[X|T_1]$ (dacă jocul nu este gata doar ultima aruncare este importantă) obținem că

$$\mathbb{E}[X|H_1] = 2p + q(1 + \mathbb{E}[X|T_1]).$$

În mod similar găsim $\mathbb{E}[X|T_1] = 2q + p(1 + \mathbb{E}[X|H_1])$. Rezolvând sistemul de două ecuații cu două necunoscute obținem soluțiile $\mathbb{E}[X|H_1] = \frac{2+q^2}{1-pq}$ și $\mathbb{E}[X|T_1] = \frac{2+p^2}{1-pq}$ de unde media este $\mathbb{E}[X] = \frac{2+pq}{1-pq}$.

Putem verifica numeric dacă formula pe care am găsit-o este corectă. Pentru aceasta vom repeta experimentul ($p = 0.3$) de $N = 10000$ de ori.


Obținem că media empirică este 2.807 iar cea teoretică este 2.797.

3 Principiul reflexiei și problema scrutinului

Să presupunem că avem n elemente $\epsilon_1, \dots, \epsilon_n \in \{-1, +1\}$ astfel încât p dintre ele iau valori de $+1$ și q dintre ele iau valori de -1 ($n = p + q$). Sumele parțiale $s_k = \epsilon_1 + \epsilon_2 + \dots + \epsilon_k$ reprezintă diferența dintre numărul de elemente de $+1$ și de elemente de -1 în primele k elemente. Observăm că

$$s_k - s_{k-1} = \epsilon_k = \pm 1, \quad s_0 = 0, \quad s_n = p - q.$$

Din punct de vedere geometric, n -uplul $(\epsilon_1, \dots, \epsilon_n)$ poate fi reprezentat cu ajutorul unei linii poligonale ce pleacă din origine și ajunge în punctul de coordonate (n, s_n) , panta fiecărui segment de lungime 1 este dată de ϵ_k ($+1$ NE și -1 SE). Linia poligonală (s_1, \dots, s_n) are al k -lea punct de abscisă k și ordonată s_k .



Dacă n și x sunt numere naturale nenule astfel ca $n = p + q$ și $x = p - q$, $p, q \in \mathbb{N}$ atunci numărul de linii poligonale (în sensul de mai sus) din origine către punctul (n, x) este dat de

$$N_{n,x} = \binom{p+q}{p}.$$



Să presupunem că în turul doi al alegerilor prezidențiale din 2019 participă doi candidați, P și Q . Dacă voturile sunt date de manieră independentă cu probabilitatea de $\frac{1}{2}$ pentru fiecare candidat și candidatul P primește p voturi iar candidatul Q primește q voturi astfel ca P să câștige ($p > q$), atunci să se calculeze probabilitatea ca pe tot parcursul numărării voturilor candidatul P să fi avut mai multe voturi decât candidatul Q .

Problema scrutinului (propusă și rezolvată de Whitworth în 1878¹) poate fi interpretată geometric prin intermediul unei linii poligonale de lungime $p + q$ în care pantele fiecărui segment reprezintă opțiunea votului pentru unul din cei doi candidați: $\epsilon_k = +1$ dacă al k -lea vot a fost pentru candidatul P și $\epsilon_k = -1$ dacă al k -lea vot a fost pentru candidatul Q . În mod similar, dată fiind o linie poligonală care pleacă din origine și ajunge în punctul $(p + q, p - q)$, aceasta poate reprezenta parcursul unui scrutin în care cei doi candidați vor avea la final p și respectiv q voturi.

Conform notațiilor precedente, putem observa că s_k reprezintă numărul voturilor cu care candidatul P conduce (sau este în urmă) imediat după cel de-al k -lea vot. Astfel cerința problemei se poate traduce în modul următor: candidatul P conduce pe tot parcursul procesului de votare dacă și numai dacă $s_1 > 0, s_2 > 0, \dots, s_n > 0$ (linia poligonală se află tot timpul deasupra axei absciselor).

¹Soluția a fost publicată în cartea Choice and chance în 1886. În 1887 Joseph Bertrand a propus o formă mai generală a problemei care a fost rezolvată de către Désiré André cu ajutorul principiului reflexiei.

The graph shows a coordinate system with a horizontal axis labeled t . A red solid line represents a function $y(t)$, which starts at a point (x, y) , fluctuates, crosses the t -axis at a point labeled t , reaches a minimum below the axis, and then rises to a point (x', y') . A blue dashed line represents a function $-y(t)$, which starts at a point $(x, -y)$, fluctuates, crosses the t -axis at the same point t , reaches a maximum above the axis, and then falls to a point $(x', -y')$. The points x and x' are marked on the t -axis, corresponding to the vertical positions of the start and end points of both functions.

Vom arăta că numărul de linii poligonale care pleacă din origine și ajung în punctul de coordonate $(p+q, p-q)$ verificând $s_1 > 0, s_2 > 0, \dots, s_n > 0$ este dat de formula:

$$N = \frac{p-q}{p+q} \binom{p+q}{p}.$$

Pagina 7

$$N = N_{n-1,x-1} - N_{n-1,x+1} = \binom{p+q-1}{p-1} - \binom{p+q-1}{p} = \frac{p-q}{p+q} \binom{p+q}{p}.$$

Probabilitatea căutată devine astfel $\frac{N_{n-1,x-1} - N_{n-1,x+1}}{N_{n,x}} = \frac{p-q}{p+q}$.

Pentru a verifica numeric rezultatul obținut să considerăm următoarea funcție care simulează scrutin-ul pentru cei doi candidați:

```
scrutin = function(sd){  
  set.seed(sd)  
  # generam voturile  
  vectscrutin = sample(c(rep("P",p),rep("Q",q)))  
  # transformam in +-1  
  vectscrutin = 2*(vectscrutin == "P") - 1  
  # calculam s_k  
  s = cumsum(vectscrutin)  
  # returnam daca avem sau nu indeplinita conditia  
  sum(s>0) == p+q  
}
```

Considerând $p = 50$ și $q = 35$ și repetând experimentul de $M = 100000$ de ori obținem că probabilitatea empirică este 0.1769 iar cea teoretică este 0.1765.

4 Legea arcsinus-ului



Să presupunem că aruncăm cu banul de 100 de ori și că înregistrăm la fiecare aruncare numărul de capete și numărul de cozi. Definim *ultima egalitate* ca fiind ultima aruncare în care numărul de capete este egal cu numărul de cozi (deci ia valori de la 0 la 100). Ne propunem să scriem un program care să determine locația ultimei egalități în jocul de noroc descris.

Vom începe prin a transpune problema în limbaj matematic². Fie $(X_n)_n$ un șir de variabile aleatoare independente ce iau valori în mulțimea $\{+1, -1\}$ cu probabilitatea $p = \frac{1}{2}$ (aruncăm cu banul și ne deplasăm la dreapta sau la stânga în funcție de rezultatul aruncării) și fie $S_n = X_1 + \dots + X_n$. Putem interpreta șirul S_1, S_2, \dots, S_n geometric, ca și în cazul problemei scrutinului, cu ajutorul unei linii poligonale cu segmentele $(k-1, S_{k-1}) \rightarrow (k, S_k)$. Fie L_{2n} variabila aleatoare care ne dă timpul ultimei întoarceri în origine a unui mers la întâmplare de lungime $2n$ (de ce avem $2n$?), cu alte cuvinte

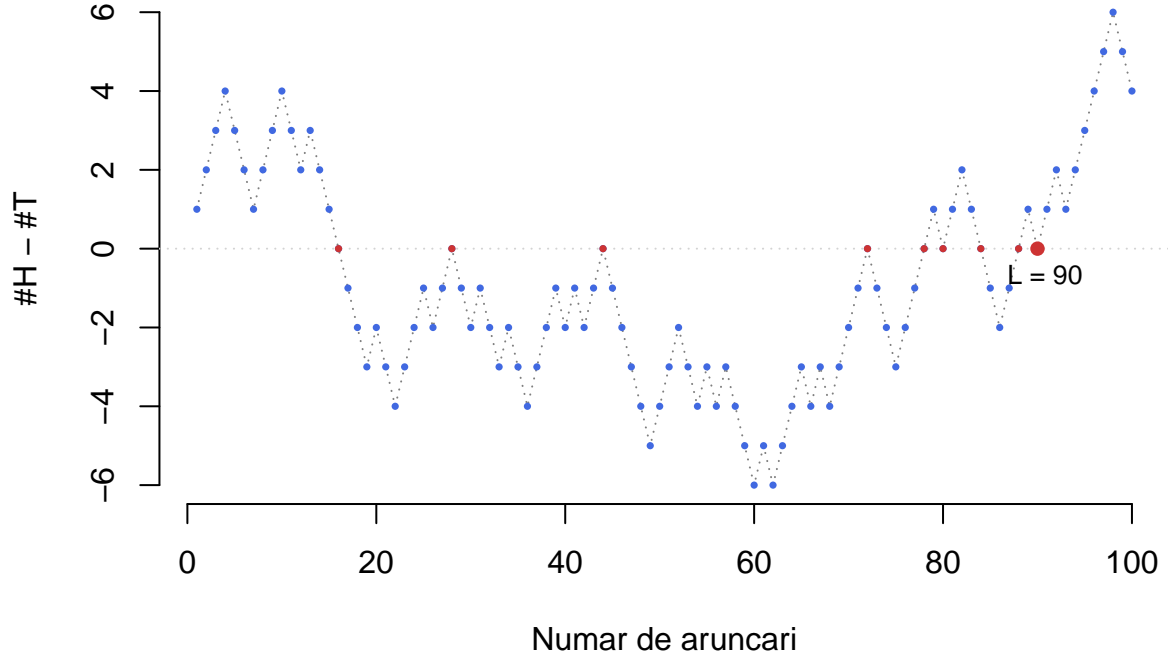
$$L_{2n} = \sup\{m \leq 2n \mid S_m = 0\}.$$

Variabila L_{2n} este variabila care descrie *ultima egalitate* din enunțul problemei și ne propunem să găsim repartiția acestei variabile aleatoare. Observăm că

$$\begin{aligned} \mathbb{P}(L_{2n} = 2k) &= \mathbb{P}(S_{2k} = 0, S_{2k+1} \neq 0, \dots, S_{2n} \neq 0) \\ &= \mathbb{P}(S_{2k} = 0) \mathbb{P}(S_{2k+1} \neq 0, \dots, S_{2n} \neq 0 \mid S_{2k} = 0). \end{aligned}$$

O realizare a variabilei L_{100} , în contextul problemei atunci când $n = 50$ este ilustrată în figura următoare.

²Această problemă este preluată din cartea lui W. Feller *Introduction to probability and its applications*, vol I, 1968, capitolul III.



Am văzut, în problema scrutinului, că $\mathbb{P}(S_n = m)$ este $\frac{N_{n,m}}{2^n}$ (numărul de linii poligonale din origine până în punctul (n, m) supra numărul total de linii poligonale cu n puncte) de unde

$$\mathbb{P}(S_n = m) = \binom{n}{\frac{n+m}{2}} 2^{-n},$$

unde folosim convenția că $\binom{n}{\frac{n+m}{2}} = 0$ dacă $\frac{n+m}{2}$ nu este un întreg între 0 și n . Astfel deducem că $\mathbb{P}(S_{2n} = 0) = \binom{2n}{n} 2^{-2n}$.

Vom arăta că pentru un mers la întâmplare care începe din origine are loc relația

$$\mathbb{P}(S_1 \neq 0, S_2 \neq 0, \dots, S_{2n} \neq 0) = \mathbb{P}(S_{2n} = 0)$$

și cum X_i sunt independente (fiecare aruncare se face de manieră independentă) atunci probabilitatea condiționată $\mathbb{P}(S_{2k+1} \neq 0, \dots, S_{2n} \neq 0 | S_{2k} = 0)$ este egală cu probabilitatea ca un mers la întâmplare de lungime $2n - 2k$, care pornește din origine, să nu mai viziteze niciodată originea în cei $2n - 2k$ pași sau

$$\mathbb{P}(S_{2k+1} \neq 0, \dots, S_{2n} \neq 0 | S_{2k} = 0) = \mathbb{P}(S_{2n-2k} = 0).$$

Prin urmare avem relația $\mathbb{P}(L_{2n} = 2k) = \mathbb{P}(S_{2k} = 0) \mathbb{P}(S_{2n-2k} = 0)$. Pentru ca demonstrația să fie completă rămâne să verificăm că

$$\mathbb{P}(S_1 \neq 0, S_2 \neq 0, \dots, S_{2n} \neq 0) = \mathbb{P}(S_{2n} = 0).$$

Cum originea nu mai este vizitată în cei $2n$ pași atunci sau $S_j > 0$ sau $S_j < 0$ pentru toți $j \in \{1, 2, \dots, n\}$. Din simetrie, aceste alternative au aceeași probabilitate deci

$$\mathbb{P}(S_1 \neq 0, S_2 \neq 0, \dots, S_{2n} \neq 0) = 2\mathbb{P}(S_1 > 0, S_2 > 0, \dots, S_{2n} > 0)$$

și aplicând problema scrutinului (linia poligonală se afla deasupra axei absciselor) avem

$$\begin{aligned} \mathbb{P}(S_1 > 0, S_2 > 0, \dots, S_{2n} > 0) &= \sum_{k=1}^n \mathbb{P}(S_1 > 0, S_2 > 0, \dots, S_{2n} > 0, S_{2n} = 2k) \\ &= \sum_{k=1}^n \frac{1}{2^{2n}} (N_{2n-1, 2k-1} - N_{2n-1, 2k+1}) \\ &= \frac{1}{2^{2n}} N_{2n-1, 1} = 2^{-2n} \binom{2n-1}{n} = 2^{-2n-1} \binom{2n}{n} \\ &= \frac{1}{2} \mathbb{P}(S_{2n} = 0), \end{aligned}$$

de unde deducem concluzia.

Se poate verifica cu ușurință că $\mathbb{P}(S_{2m} = 0) \approx \frac{1}{\sqrt{\pi m}}^3$ pentru m suficient de mare, astfel

$$\mathbb{P}(L_{2n} = 2k) = \mathbb{P}(S_{2k} = 0) \mathbb{P}(S_{2n-2k} = 0) \approx \frac{1}{\sqrt{\pi n}} \times \frac{1}{\sqrt{\pi(n-k)}} = \frac{1}{\pi \sqrt{k(n-k)}}.$$

Observăm că pentru $\frac{k}{n} \rightarrow x$ avem $n\mathbb{P}(L_{2n} = 2k) \rightarrow \frac{1}{\pi \sqrt{x(1-x)}}$. Dacă $0 < a < b < 1$ și considerăm $2na_n$ cel mai mic întreg par mai mare decât $2na$ și respectiv $2nb_n$ cel mai mare întreg par mai mic decât $2nb$ atunci

$$\begin{aligned} \mathbb{P}\left(a < \frac{L_{2n}}{2n} < b\right) &= \sum_{k=na_n}^{nb_n} nb_n \mathbb{P}(L_{2n} = 2k) \\ &\approx \sum_{k=na_n}^{nb_n} nb_n \frac{1}{\pi \sqrt{k(n-k)}} \approx \frac{1}{\pi} \int_{na}^{nb} \frac{1}{\sqrt{x(n-x)}} dx \\ &\stackrel{y=nx}{=} \frac{1}{\pi} \int_a^b \frac{1}{\sqrt{y(1-y)}} dy. \end{aligned}$$

În concluzie am obținut că

$$n\mathbb{P}(L_{2n} = 2k) \rightarrow \frac{1}{\pi \sqrt{x(1-x)}}$$

și

$$\mathbb{P}\left(a < \frac{L_{2n}}{2n} < b\right) \approx \frac{1}{\pi} \int_a^b \frac{1}{\sqrt{y(1-y)}} dy = \frac{2}{\pi} (\arcsin \sqrt{b} - \arcsin \sqrt{a}).$$

Următoarea histogramă, pentru care am considerat că experimentul constă din $n = 1000$ de aruncări cu banul și pe care l-am repetat de $M = 10000$ de ori, ilustrează grafic *legea arcsinusului* pentru problema noastră:

³Din formula lui Stirling avem că $n! \approx \sqrt{2\pi n} n^{n+\frac{1}{2}} e^{-n}$ prin urmare $\binom{2n}{n} 2^{-2n} \approx \frac{\sqrt{2\pi(2n)}^{2n+\frac{1}{2}} e^{-2n}}{\left(\sqrt{2\pi n}^{n+\frac{1}{2}} e^{-n}\right)^2} 2^{-2n} = \frac{1}{\sqrt{\pi n}}$

Histograma ultimei egalitati

